

Asistente de normativa de pregrado (Ingeniería UdeC): diagnóstico de falla y selección de modelo

Generative Artificial Intelligence (580694) · Entregable 1 · Segundo semestre 2026

Equipo: Álvaro Contreras y Pablo Cortés

Repositorio: <https://github.com/alnicozu/GENERATIVE-ARTIFICIAL-INTELLIGENCE-DELIVERABLE-1>

1. Especificación de la tarea

La tarea recibe una pregunta en español sobre la normativa de pregrado de la Facultad de Ingeniería (FI) de la UdeC y la responde a partir de un corpus cerrado de tres documentos oficiales públicos: el Reglamento General de Docencia de Pregrado (RG), el Reglamento Interno de Docencia de Pregrado de la FI (RI-FI) y el Calendario de Docencia de Pregrado 2026 (CAL). Una respuesta es correcta cuando entrega el dato exacto y cita el artículo o fuente que lo respalda; si la información no está en el corpus, o la pregunta parte de una premisa falsa, lo correcto es advertir que no existe en vez de inventarla. La métrica es la exactitud estricta (se cuenta acierto solo si el dato y el artículo son correctos), reportada por cada una de las cinco categorías: factual, numérica, condicional, cruce entre documentos y abstención.

2. Diagnóstico de la falla (con evidencia)

Como línea base evaluamos Qwen3-4B en modo zero-shot, con prompting directo y sin entregarle los documentos, usando decodificación determinista. El conjunto de prueba es propio: 50 preguntas (10 por categoría) con respuesta de referencia verificada directamente contra los PDF.

Categoría	Aciertos	Exactitud
Factual	0/10	0%
Numérica	0/10	0%
Condicional	0/10	0%
Cruce entre documentos	0/10	0%
Abstención (premisa falsa)	2/10	20%
Global	2/50	4%

El resultado central es que, en las 40 preguntas cuya respuesta está en el corpus, el modelo no acierta ninguna: la falla es total en las cuatro categorías con respuesta. El mecanismo es la ausencia paramétrica, es decir, el corpus no está en los pesos del modelo, de modo que ante una pregunta específica inventa con confianza. En la corrida real dio cifras falsas (60 créditos cuando el mínimo es 8; 18 semanas en vez de 19), citó artículos al azar (Art. 12 o Art. 10 para casi todo), inventó una escala (0 a 7, cuando la oficial es 1 a 7) y una fecha (15 de enero en vez del 04-sep-2026), e incluso un “Reglamento de Feriados Nacionales” que no existe.

Más revelador aún, ante preguntas de premisa falsa (artículos o incisos inexistentes, como el Art. 90 o el inciso “d” del Art. 14) redactó su contenido íntegro en 8 de 10 casos en lugar de advertir que no existen. En paralelo, negó (“no está en la normativa”) datos que sí existen, por lo que su abstención está descalibrada: inventa cuando debería abstenerse y se abstiene cuando debería responder.

La falla no depende del tamaño. El mismo conjunto evaluado con Qwen3-8B (el doble de parámetros, el máximo permitido) da igualmente 2/50 (4%); el modelo mayor a veces razona mejor, pero tampoco cita el artículo correcto porque carece de la fuente. Por eso la falla la resuelve el harness (el sistema en torno al modelo, en este caso RAG) y no un modelo más grande.

3. Modelos candidatos (menores o iguales a 8B, open-weight)

El criterio de selección es la calidad en español, el seguimiento de instrucciones y una licencia realmente abierta (Apache 2.0).

Modelo	Par.	Licencia	Rol
Qwen3-4B	4B	Apache 2.0	Principal
Salamandra-7B-inst.	7B	Apache 2.0	Alt. español
Qwen3-8B	8B	Apache 2.0	Cota superior

Según el Reporte Técnico de Qwen3, Qwen3-4B casi iguala al 8B en lo relevante para la tarea: IFEval 81,9 frente a 85,0 (seguimiento de instrucciones y formato), Multi-IF 66,3 frente a 71,2 (instrucciones multilingües) y MMMLU en 14 idiomas 69,8 frente a 74,4. En IberBench, una evaluación independiente en lenguas ibéricas, los mejores modelos se concentran entre 3 y 10B y Salamandra-7B rinde a la par de Qwen2.5-7B, mientras que los modelos bajo 3B quedan por debajo. Salamandra (Barcelona Supercomputing Center) aporta español desde el preentrenamiento y cuenta con un derivado jurídico-administrativo (ALIA) afín al dominio; Qwen3-8B se incluye como cota superior y confirma que el modelo grande también falla (4%).

Elegimos Qwen3-4B como modelo principal, notablemente menor que 8B, y lo defendemos por la tarea: el conocimiento vive en un corpus pequeño recuperable por RAG y no en los pesos, y como IberBench muestra que bajo 3B el rendimiento en español cae, 4B es el tamaño mínimo seguro que conserva calidad multilingüe siendo la mitad del límite.

4. Viabilidad de ejecución

Qwen3-4B corre en Google Colab gratis (GPU NVIDIA T4, cerca de 15 GB) usando 6,44 GB de VRAM en precisión bf16, cargado con la librería `transformers`. El cuaderno reproducible (`.ipynb`), versionado en el repositorio ya ejecutado, evidencia la GPU, el modelo cargado y el consumo de VRAM en sus propias salidas. El candidato de 8B corre en la misma T4 con cuantización de 4 bits.

5. Repositorio y estado

El repositorio (<https://github.com/alnicozu/GENERATIVE-ARTIFICIAL-INTELLIGENCE-DELIVERABLE-1>) contiene la definición de la tarea, los integrantes del equipo, el estado del trabajo, los cuadernos de Colab ya ejecutados (4B y 8B, con sus salidas visibles) y el conjunto de prueba (50 preguntas con su respuesta de referencia). La tarea, el modelo y la línea base están definidos y medidos; el próximo paso es implementar RAG y medir la mejora contra este baseline (4%).

Fuentes de benchmarking: Qwen3 Technical Report (arXiv:2505.09388); IberBench (arXiv:2504.16921); La Leaderboard (BSC/Hugging Face).