Agentes para consultas de normativa de pregrado

Ingeniería UdeC · Entregable 3 · Arquitectura, decisiones y ablaciones de v6

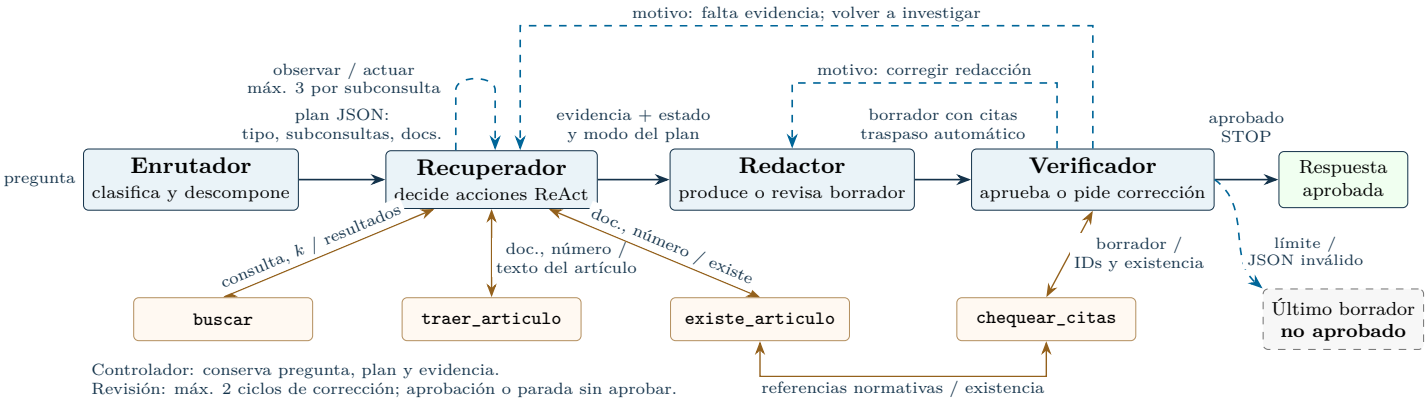
Generative Artificial Intelligence (580694) · Segundo semestre 2026 Álvaro Contreras y Pablo Cortés

Repositorio y reproducción: D3 alvaro / README **Video (≤3 min):** Pendiente de enlace público

1. Continuidad, tarea y modelo

Continuamos D1/D2: consultas al Reglamento General, al Reglamento Interno de Ingeniería y al Calendario UdeC 2026 (**197 unidades, 201 fragmentos**). Un acierto exige respuesta suficiente, cita que la respalde y ningún añadido falso; se admite abstención justificada. D2 omite excepciones, cruces y atribuye datos a citas inadecuadas. D3 conserva corpus, embeddings E5 y **Qwen/Qwen3-4B** de pesos abiertos en todos los roles (NF4, T4, temperatura 0,7; thinking nativo desactivado), agregando planificación y revisión. CoT se induce por prompt. Evaluamos las **50 consultas originales y 25 difíciles** de cálculo, cruces, excepciones y premisas falsas.

2. Grafo y condiciones de parada



Continuas: flujo; discontinuas: revisión/parada; dobles: argumentos y resultados de herramientas. El tipo del Enrutador activa la comprobación de artículos en premisas falsas. E5 recupera evidencia; no es otro modelo agente.

3. Roles, contratos y técnicas

Prompts propios en `prompts/01-04`. Enrutador, Recuperador y Verificador deciden rutas o paradas. El controlador transfiere siempre el borrador del Redactor al Verificador.

Enrutador. Pregunta → JSON {tipo, sub_consultas, documentos}. Clasifica, descompone y fija el modo; entrega el plan. Sin herramientas directas. **Few-shot**: guía cruces y premisas falsas.

Recuperador. Subconsulta, evidencia y observación → JSON {accion, args}, evidencia y estado. Elige `buscar`, `traer`, `existe` o `suficiente`; hasta tres acciones por subconsulta. **ReAct**: re-busca según lo observado.

Redactor. Pregunta, modo, evidencia y objeciones → Respuesta / Condiciones / Fuente. Redacta, corrige o declara falta de respaldo; sin herramientas directas. **CoT por prompt**: aborda cálculos y excepciones; se retira el razonamiento de la respuesta visible.

Verificador. Pregunta, borrador, evidencia y `chequear_citas` → JSON {aprobado, destino, motivo}. Aprueba o devuelve objeciones al Redactor o Recuperador. **Self-refine con criterios**: revisa suficiencia y citas.

División del trabajo. Planificar determina qué buscar; recuperar reúne respaldo; redactar responde; verificar aplica criterios en otra llamada. Permite corregir la fase necesaria, pero no garantiza independencia entre llamadas al mismo modelo.

4. Ablaciones y alcance

Sin few-shot: elimina ejemplos del Enrutador. **Sin CoT:** elimina la instrucción del Redactor; el Verificador la conserva. **Sin ReAct:** elimina ciclo y llamadas del Recuperador, manteniendo la búsqueda base. **Sin Verificador:** toma el primer borrador de v6 desde las trazas; no es otra corrida GPU. Las dos últimas eliminan componentes completos.

Mismos conjuntos y pauta por condición. La semilla depende del prompt: cambiarlo altera también el muestreo. Hay una corrida por condición; diferencias de uno o dos aciertos no prueban ventajas estables. Las preguntas se usaron durante desarrollo, por lo que no se demuestra generalización.

5. Resultados y contribuciones

Corrección externa propuesta con Claude según la pauta de D2 y motivos por fila; **nueve casos v6 siguen en revisión**. Se evalúa el texto final, aunque no tenga aprobación interna.

Configuración	Base (50)	Dif. (25)	Llam.
Directo	1 (2 %)	0 (0 %)	1
RAG D2	40 (80 %)	16 (64 %)	1
Completo v6	**46 (92 %)**	**20 (80 %)**	**9,5**
Sin few-shot	44 (88 %)	19 (76 %)	10,7
Sin ReAct	45 (90 %)	18 (72 %)	3,9
Sin CoT (Redactor)	46 (92 %)	19 (76 %)	8,3
Sin Verificador	44 (88 %)	19 (76 %)	6,4

Aciertos (porcentaje). Llam.: media de llamadas al modelo por pregunta, sobre 75 entradas; excluye herramientas automáticas.

Frente a D2: **7 mejoras y 1 regresión** en las originales (+12 puntos porcentuales); **6 mejoras y 2 regresiones** en las difíciles (+16 puntos).

Sin ReAct se pierden dos aciertos difíciles; H05 queda sin evidencia para calcular. Sin few-shot, las clasificaciones de premisa falsa bajan de 14 a 6. Sin CoT se empata en las originales y el tiempo medio baja de 110 a 55 s. Verificar añade tres aciertos netos sobre 75 respecto del primer borrador, con una regresión en H07.

6. Fallo, costo y límites

H03: días entre inicio de clases y modificación. Faltan fechas entre las seis evidencias; el Redactor inventa 31 y 262 días. El Verificador rechaza, pero la revisión y re-búsqueda no resuelven la carencia: termina **no aprobado tras 19 llamadas**. Traza: `resultados_v6/trazas_D3.json`, clave `dificil_25:H03`.

Aprobar no equivale a acertar: siete de 64 aprobaciones son incorrectas; nueve aciertos son borradores rechazados. El Verificador recibe hasta 700 caracteres por unidad; comprobar citas no garantiza respaldo semántico. Costo de v6: **711 llamadas / 75** = 9,48 y 110 s por pregunta en T4.

7. Reproducción y trazabilidad

`D3 alvaro/README.md` enlaza Colab, prompts, CSV, planillas y trazas por entrada. `Demo_D3.ipynb` muestra mensajes de una consulta y permite inspeccionar H03 histórico. `auditar.py` verifica hashes y correspondencia CSV/trazas. Se conserva el ZIP original; el entorno se registra, sin garantizar identidad con versiones históricas no fijadas.