Agentes para consultas de normativa de pregrado

Ingeniería UdeC · Entregable 3 · Diseño y evaluación del sistema v6

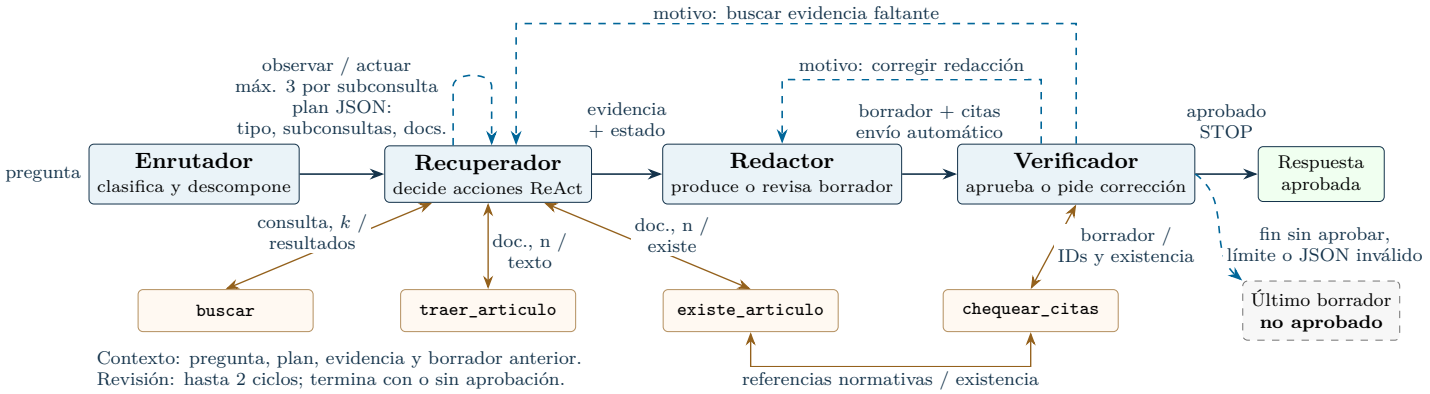
Generative Artificial Intelligence (580694) · Segundo semestre 2026 Álvaro Contreras y Pablo Cortés

Repositorio y reproducción: D3 alvaro / README **Video (≤3 min):** Pendiente de enlace público

1. Continuidad, tarea y modelo

Continuamos D1/D2: consultas al Reglamento General, al Reglamento Interno de Ingeniería y al Calendario UdeC 2026 (**197 unidades, 201 fragmentos**). Una respuesta correcta es suficiente, está respaldada por citas y no añade afirmaciones falsas; se admite abstención justificada. D2 falla al aplicar excepciones, combinar normas y respaldar respuestas. D3 añade planificación y revisión, manteniendo corpus, embeddings E5 y **Qwen/Qwen3-4B** de pesos abiertos en todos los roles (NF4, T4, temperatura 0,7). El razonamiento nativo está desactivado; CoT se solicita por prompt. Evaluamos las **50 consultas originales y 25 difíciles**.

2. Grafo y condiciones de parada



Continuas: flujo; discontinuas: revisión/parada; bidireccionales: consulta y resultado de herramientas. El Enrutador activa la comprobación de artículos ante premisas falsas. E5 recupera evidencia; no es otro modelo agente.

3. Roles, contratos y técnicas

Cada rol tiene un prompt en `prompts/01-04`. Enrutador, Recuperador y Verificador deciden cómo continuar o detenerse. El controlador envía siempre el borrador al Verificador.

Enrutador. Recibe la pregunta y entrega un plan JSON {tipo, sub_consultas, documentos}. Clasifica, descompone y define el modo de respuesta; no usa herramientas directas. **Few-shot**: ejemplos para orientar clasificación y descomposición.

Recuperador. Recibe subconsulta, evidencia y última observación. Elige una acción JSON {accion, args}: `buscar`, `traer`, `existe` o `suficiente`. Entrega evidencia y estado. Termina cada subconsulta por suficiencia, artículo inexistente o tres acciones. **ReAct**: adapta la búsqueda a sus resultados.

Redactor. Recibe pregunta, modo, evidencia y objeciones; v6 no incluye el borrador anterior en su prompt. Produce Respuesta / Condiciones / Fuente; corrige o declara falta de respaldo. No usa herramientas directas. **CoT por prompt**: razona sobre cálculos y excepciones; ese bloque se retira de la respuesta final.

Verificador. Recibe pregunta, borrador, evidencia y resultado de `chequear_citas`. Devuelve JSON {aprobado, destino, motivo}: termina o solicita correcciones al Redactor o Recuperador. **Self-refine**: revisión iterativa de suficiencia y citas.

División del trabajo. Separar planificación, búsqueda, redacción y revisión permite corregir la etapa que falla. Usar el mismo modelo no garantiza independencia entre sus juicios.

4. Ablaciones y alcance

Sin few-shot: retira ejemplos del Enrutador. **Sin CoT:** retira la instrucción del Redactor; conserva la del Verificador. **Sin ReAct:** elimina ciclo y llamadas del Recuperador, manteniendo la búsqueda inicial. **Sin Verificador:** evalúa el primer borrador guardado en las trazas de v6; no es otra ejecución GPU. Estas dos últimas variantes eliminan componentes completos.

Todas usan las mismas consultas y pauta. La semilla depende del prompt: modificarlo cambia también el muestreo. Una ejecución por condición y diferencias de uno o dos aciertos no establecen ventajas robustas. Las consultas se usaron durante el desarrollo; no se demuestra generalización.

5. Resultados provisionales

Calificación propuesta con apoyo de Claude, según la pauta de D2 y con justificación por caso. **Nueve casos de v6 requieren revisión**. Se evalúa el texto final, independientemente de la aprobación interna.

Configuración	Originales	Difíciles	Llamadas
Directo	1 (2 %)	0 (0 %)	1
RAG D2	40 (80 %)	16 (64 %)	1
Completo v6	**46 (92 %)**	**20 (80 %)**	**9,5**
Sin few-shot	44 (88 %)	19 (76 %)	10,7
Sin ReAct	45 (90 %)	18 (72 %)	3,9
Sin CoT (Redactor)	46 (92 %)	19 (76 %)	8,3
Sin Verificador	44 (88 %)	19 (76 %)	6,4

Aciertos (porcentaje). Llamadas: promedio al modelo por consulta, sobre 75 entradas; no incluye herramientas automáticas.

Frente a D2: **7 mejoras y 1 regresión** en las originales (+12 puntos porcentuales); **6 mejoras y 2 regresiones** en las difíciles (+16 puntos).

Sin ReAct hay dos aciertos menos en las difíciles; H05 no recupera evidencia para calcular. Sin few-shot hay dos aciertos originales y uno difícil menos. Sin CoT se empata en las originales y el tiempo medio baja de 110 a 55 s. La revisión aporta tres aciertos netos frente al primer borrador, aunque empeora H07.

6. Fallo, costo y límites

H03: plazo para modificar asignaturas en cada semestre. La evidencia seleccionada omite fechas necesarias y el primer borrador inventa 31 y 262 días. El Verificador rechaza, pero las nuevas búsquedas y correcciones no lo resuelven: termina **no aprobado tras 19 llamadas**. Traza: `resultados_v6/trazas_D3.json`, clave `dificil_25:H03`.

Aprobar no equivale a acertar: siete de 64 aprobaciones son incorrectas; nueve aciertos son borradores rechazados. El Verificador recibe hasta 700 caracteres por unidad; comprobar citas no garantiza respaldo semántico. Promedio de v6: 9,48 llamadas y 110 s por consulta (711 llamadas en 75 consultas, T4).

7. Reproducción y trazabilidad

`D3 alvaro/README.md` enlaza Colab, prompts, CSV, planillas y trazas resumidas por consulta. `Demo_D3.ipynb` permite ejecutar una consulta e inspeccionar H03 histórico; `auditar.py` comprueba archivos y concordancia CSV/trazas. Se conserva el ZIP original, pero no todas las versiones del entorno; no se garantizan resultados idénticos.