


# Asistente RAG de normativa de pregrado

## Tarea, modelo e intervención

El asistente responde preguntas sobre tres documentos de la Universidad de Concepción: Reglamento General de Docencia, Reglamento Interno de Ingeniería y Calendario 2026. Una respuesta válida debe dar el dato suficiente, citar una fuente pertinente y no añadir afirmaciones falsas. En Deliverable 1, el prompt directo sin corpus obtuvo **2/50 (4 %)**: predominaban datos inventados, negativas indebidas y citas sin respaldo. Se eligió **Qwen/Qwen3-4B**, revisión 1cfa9a720891, entre Qwen3-4B, Salamandra-7B y Qwen3-8B: es el menor en parámetros y puede recibir el conocimiento específico mediante recuperación. En E1, Qwen3-8B también obtuvo 2/50 con prompt directo; Salamandra-7B quedó como candidato no ejecutado. La solución usa Qwen3-4B en NF4 de 4 bits, sin thinking, en una Tesla T4.

## Sistema ejecutado de extremo a extremo



Los tres PDF se segmentaron en **197 unidades normativas completas** y **201 fragmentos de búsqueda**. E5 recupera en cada consulta; el sistema expande los hallazgos a artículos o eventos íntegros antes de pasarlos al modelo. Las respuestas de referencia no entran en la generación.

## Estrategias y resultados medidos

Las mismas **50 preguntas conocidas** se evaluaron con la misma pauta de contenido y citas. La nueva comparación emparejó modelo, cuantización, muestreo y semilla por pregunta; cambió la intervención (evidencia y prompt). Los veredictos son una revisión asistida, registrada por respuesta.

| Condición                        | Correctas           | Lectura                                                    |
|----------------------------------|---------------------|------------------------------------------------------------|
| Baseline directo, sin documentos | 1/50 (2 %)          | Corrida emparejada nueva; no sustituye el 4 % histórico.   |
| RAG simple                       | 39/50 (78 %)        | Alternativa con instrucción breve.                         |
| RAG estructurado, elegido        | <b>40/50 (80 %)</b> | Dato, límites y fuente; repetido con recuperación en vivo. |
| RAG estructurado + few-shot      | 36/50 (72 %)        | Ejemplos ficticios contaminaron algunas citas; se retiró.  |

En la comparación emparejada, RAG acertó 39 preguntas que falló el baseline; ambos acertaron una y fallaron diez. Las 100 salidas terminaron normalmente, sin cortes detectados.

## Fallo observado y límites

**P25:** al preguntar qué asignaturas no se pueden eliminar al modificar la inscripción, RAG respondió solo «prioridades a) y b)». Los arts. 7 y 9 de RI-FI estaban completos en el contexto, pero el modelo no explicó que son las asignaturas atrasadas y las obligatorias reprobadas aún no aprobadas. Es un **fallo de síntesis**, no de fragmentación ni de truncamiento. En P38, además, la recuperación no aportó el art. 2 pertinente y el modelo citó el art. 6, sobre cupos.

Las 50 preguntas guiaron el desarrollo del recuperador: este resultado **no mide generalización** a preguntas nuevas. La comparación mide recuperación *más* prompt estructurado, no el efecto aislado de cada componente; usa una semilla y juicio asistido auditable. El [repositorio](#) permite auditar el cuaderno, el ZIP de Colab, la pauta y cada veredicto; la sección 7 del cuaderno verifica su correspondencia en la misma sesión.