

Workshop 1: Espacio Semántico del Discurso de Odio

Inteligencia Artificial Generativa (580694)

1. 1. Construcción del Corpus

Se utilizó el dataset público *Automated Hate Speech Detection* (Davidson et al.), extraído de su repositorio oficial en GitHub. El corpus para este análisis se compone de **2.000 documentos** (tuits reales extraídos de la red social X). El largo de los documentos está limitado a textos cortos (máximo 280 caracteres). El **atributo adicional** es la etiqueta de moderación humana, la cual clasifica el texto en dos categorías: *Discurso de Odio / Ofensivo* (1.000 documentos) o *Normal / Sano* (1.000 documentos).

2. 2. Generación de Embeddings

Para transformar los textos a representaciones matemáticas, se empleó el modelo de lenguaje **all-MiniLM-L6-v2** mediante la librería *SentenceTransformers*. Este modelo, optimizado para capturar similitud semántica en oraciones cortas, genera vectores con una **dimensionalidad de 384**.

3. 3. Proyección a Dos Dimensiones

Para visualizar el hiperespacio, se aplicó el algoritmo de reducción de dimensionalidad no lineal **UMAP**. Tras evaluar diversas proyecciones, la configuración óptima para revelar la estructura latente fue el uso de 15 vecinos cercanos (**n_neighbors=15**) y una distancia mínima de 0.1 (**min_dist=0.1**).

4. 4. Cruce de Atributos y Análisis Espacial

Al cruzar el espacio vectorial (generado exclusivamente desde el texto) con el atributo humano de clasificación, se revelan patrones estructurales significativos. El modelo agrupó naturalmente casi la totalidad del discurso tóxico (rojo) en un denso y único clúster en el cuadrante superior derecho. En contraste, el lenguaje sano (verde) se distribuye en múltiples subgrupos aislados. Esto evidencia que el discurso de odio comparte una semántica y vocabulario muy repetitivo, mientras que el discurso normal abarca temáticas muy variadas. Además, se observan anomalías (puntos rojos inmersos en zonas verdes), las cuales exponen los límites de la lectura léxica del modelo frente a fenómenos como el sarcasmo o la ironía humana.




Figura 1: Mapa bidimensional UMAP coloreado según el cruce con el atributo de toxicidad.