Arquitectura multi-agente para el asistente de normativa (Ingeniería UdeC)

Entregable 3: sistema de tres agentes con decisiones observables, herramientas y estudio de ablación

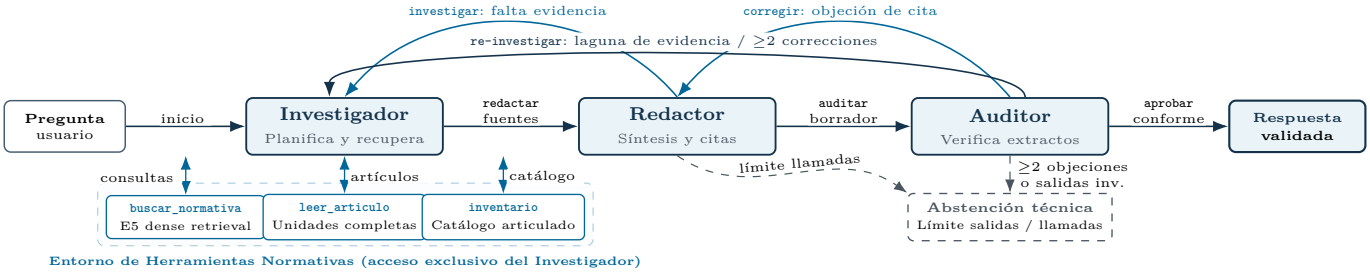
Generative Artificial Intelligence (580694) | Segundo semestre 2026 | **Equipo:** Álvaro Contreras y Pablo Cortés

Repositorio: github.com/Pacortes2021/GENERATIVE-ARTIFICIAL-INTELLIGENCE-DELIVERABLE-1 **Video (3 min):** [Enlace de video]

1. Continuidad con E1/E2 y definición de agentes

Este entregable continúa la tarea de responder consultas en español sobre la normativa de pregrado de la Facultad de Ingeniería (FI-UdeC) a partir del corpus cerrado oficial (Reglamento General RG, Reglamento Interno RI-FI y Calendario 2026: 197 unidades, 201 fragmentos E5). Se mantiene la pauta estricta: acierto solo si el dato es suficiente y la cita lo respalda; abstención si la información no existe o la premisa es falsa. Ratificamos **Qwen/Qwen3-4B** (NF4, GPU Tesla T4, temp = 0,7, sin thinking) compartido por todos los agentes. A diferencia de un pipeline fijo de prompts, los agentes toman **decisiones observables**: invocan herramientas, transfieren el control con contratos JSON validados, reintentan ante objeciones o se detienen.

2. Arquitectura del sistema y grafo de agentes



Roles diferenciados y contratos JSON: Investigador: descompone la consulta, planifica y recupera evidencia con herramientas normativas. **Redactor:** sintetiza la respuesta condicionada a la evidencia recuperada y formula citas oficiales. **Auditor:** verifica extracto por extracto el respaldo literal de cada afirmación; objeta o exige re-búsqueda.

3. Técnicas de prompting y estudio de ablación

Cada técnica ataca una falla diagnosticada en E1/E2 mediante bloques modulares concatenados a los prompts en `prompts/`:

- **Descomposición (Investigador):** Divide preguntas complejas en sub-consultas vectoriales. Ablación: `sin_descomposicion`.
- **Completitud (Redactor):** Chequeo de condiciones, excepciones y remisiones. Ablación: `sin_completitud`.
- **Verificación (Auditor):** Validación estricta extracto a extracto contra el corpus. Ablación: `sin_verificacion`.

4. Resultados empíricos y análisis comparativo

Se evaluaron en GPU T4 las 6 condiciones experimentales sobre los dos bancos bajo la pauta de E2 (450 inferencias en total):

Configuración	Base (50)	Sust. (40)	Difícil (25)	Llam.
Directo (E1)	1/50 (2 %)	1/40 (3 %)	0/25 (0 %)	1,0
RAG Monolítico (E2)	40/50 (80 %)	30/40 (75 %)	16/25 (64 %)	1,0
Multi-Agente (E3)	**34/50 (68 %)**	**34/40 (85 %)**	**11/25 (44 %)**	**5,1**
– sin descomp.	34/50 (68 %)	32/40 (80 %)	14/25 (56 %)	5,4
– sin complet.	34/50 (68 %)	33/40 (83 %)	12/25 (48 %)	5,2
– sin verific.	32/50 (64 %)	31/40 (78 %)	14/25 (56 %)	4,9

Tabla 1: Evaluación experimental en GPU T4 (Qwen3-4B, 450 corridas). *Base*: conjunto D1/D2 (50). *Sust.*: preguntas P01–P40 con respaldo normativo expreso. *Difícil*: conjunto H01–H25. *Llam.*: promedio de llamadas al modelo por consulta.

Victorias cualitativas y hallazgos sustantivos:

1. **Especialización sustantiva:** En el subconjunto normativo (P01–P40), los agentes superan a RAG D2 por **+10,0 pp (85 % vs 75 %)**, resolviendo 9 de las 10 fallas históricas de D2 (omisiones P11, P15, P24, P25, P36 y colisiones P01, P28, P30, P38).
2. **Razonamiento multi-regla complejo:** En el banco difícil, los agentes resuelven taxativamente casos de alta jerarquía normativa: **H18** (tope de 36 créditos para memoristas suspendidos > 3 años, Art. 31 RI-FI) y **H25** (criterio jerárquico de prelación en Plan Común: créditos aprobados, promedio curricular con dos decimales y cupos, Art. 5 RI-FI); además de computar con exactitud algebraica las notas de titulación 60/40 en **H05 y H08** (Art. 30 RI-FI), donde RAG D2 fracasó por carecer de cálculo aritmético.

5. Diagnóstico de fallos, sobre-cautela y coste

- **Sobre-cautela del Auditor:** En el set difícil, `agentes_completo` logró un **78,6 % de acierto al emitir respuesta** (11 de 14). Sin embargo, en 11 preguntas el Auditor rechazó borradores por mínimas discrepancias léxicas en los extractos hasta agotar presupuesto (6 por `limite_salidas_invalidas` y 5 por `limite_llamadas`), forzando abstenciones técnicas penalizadas con 0.
- **Efecto liberador de las ablaciones:** Al retirar verificación (`sin_verificacion`), se evitó el rechazo léxico hiper-estricto, permitiendo emitir respuestas correctas en casos conflictivos (H10, H12, H22) y elevando los aciertos a 14/25 (56 %). De modo análogo, `sin_descomposicion` ahorró presupuesto de llamadas, resolviendo consultas extensas como H25 (14/25, 56 %).
- **Coste computacional:** Los agentes demandan 5,1 llamadas y ∼152 s por pregunta frente a 1 llamada y 15 s de RAG D2.

6. Reproducibilidad y repositorio

El repositorio contiene el código ejecutable, prompts versionados en archivos externos, semillas y trazas completas de las 450 respuestas con 25 snapshots ZIP inmutables. El cuaderno en Colab permite reproducir las corridas en GPU T4 de forma directa.