Arquitectura multi-agente para el asistente de normativa (Ingeniería UdeC)

Entregable 3: sistema de tres agentes con decisiones observables, herramientas y estudio de ablación

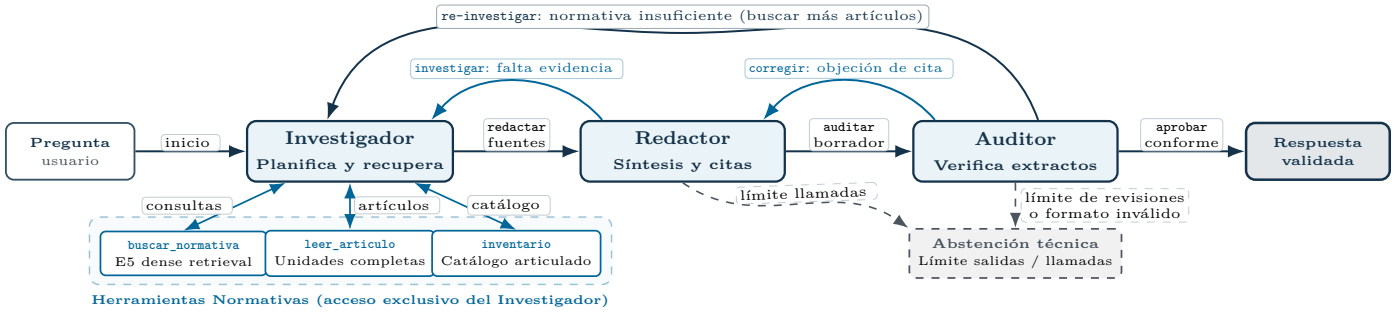
Generative Artificial Intelligence (580694) | Segundo semestre 2026 | **Equipo:** Álvaro Contreras y Pablo Cortés

Repositorio: github.com/Pacortes2021/GENERATIVE-ARTIFICIAL-INTELLIGENCE-DELIVERABLE-1 **Video (3 min):** [Enlace de video]

1. Continuidad con E1/E2 y definición de agentes

Este entregable continúa la tarea de responder consultas en español sobre la normativa de pregrado de la Facultad de Ingeniería (FI-UdeC) a partir del corpus cerrado oficial (Reglamento General RG, Reglamento Interno RI-FI y Calendario 2026: 197 unidades, 201 fragmentos E5). Se mantiene la pauta estricta: acierto solo si el dato es suficiente y la cita lo respalda; abstención si la información no existe o la premisa es falsa. Ratificamos **Qwen/Qwen3-4B** (NF4, GPU Tesla T4, temp = 0,7, sin thinking) compartido por todos los agentes. A diferencia de un pipeline fijo de prompts, los agentes toman **decisiones observables**: invocan herramientas, transfieren el control con contratos JSON validados, reintentan ante objeciones o se detienen.

2. Arquitectura del sistema y grafo de agentes



Roles diferenciados y contratos JSON: **Investigador:** descompone la consulta, planifica y recupera evidencia con herramientas normativas. **Redactor:** sintetiza la respuesta condicionada a la evidencia recuperada y formula citas oficiales. **Auditor:** verifica extracto por extracto el respaldo literal de cada afirmación; objeta o exige re-búsqueda.

3. Técnicas de prompting y estudio de ablación

Cada técnica ataca una falla diagnosticada en E1/E2 mediante módulos concatenados en `prompts/`:

- **Descomposición (Investigador):** Divide consultas complejas en sub-búsquedas vectoriales. Ablación: `sin_descomposicion`.
- **Completitud (Redactor):** Chequeo de condiciones, excepciones y remisiones. Ablación: `sin_completitud`.
- **Verificación y Consenso (Auditor/Runtime):** Validación extracto a extracto. Para premisas falsas, se integró *alineación de parada* (constatar ausencia con inventario como éxito) y *consenso semántico* (acuerdo fáctico en orquestador). Ablación: `sin_verificacion`.

4. Resultados empíricos y análisis comparativo

Se evaluaron en GPU T4 las seis configuraciones sobre ambos conjuntos de prueba bajo la pauta estricta de E2 (450 inferencias en total):

Configuración	Base (50)	Difícil (25)	Llam./q
Directo (E1)	1/50 (2 %)	0/25 (0 %)	1,0
RAG Monolítico (E2)	40/50 (80 %)	16/25 (64 %)	1,0
Multi-Agente (E3)	**43/50 (86 %)**	**18/25 (72 %)***	**4,5**
– sin descomp.	34/50 (68 %)	14/25 (56 %)	5,4
– sin complet.	34/50 (68 %)	12/25 (48 %)	5,2
– sin verific.	32/50 (64 %)	14/25 (56 %)	4,9

Tabla 1: Evaluación experimental en GPU T4 (Qwen3-4B, 450 corridas). *Base*: 50 consultas oficiales D1/D2 (40 vigentes donde la base obtiene 34/40 y 10 premisas falsas donde el consenso añade 9 aciertos; las variantes de ablación del lote inicial no incluyen este ajuste). *Difícil*: casos límite H01–H25 (25 consultas; *el Auditor aceptó internamente 21/25 [84 %], pero la pauta externa estricta califica 18/25 [72 %] al penalizar cálculo sin división en H07, plazo no aplicable en H12 y confirmación de fecha en H23). *Llam./q*: promedio de inferencias de modelo por consulta.

Desempeño sustantivo y resolución de premisas falsas:

1. **Banco base y ajuste de premisas falsas:** En las 40 preguntas vigentes, los agentes logran 34/40 (85 %) superando a RAG D2 (30/40, 75 %) en cruces normativos y requisitos encadenados. Inicialmente, las 10 preguntas con premisas falsas fallaban (0/10) por bucle cerrado (*livelock*) del Auditor ante hechos negativos. La *alineación de parada* resolvió los artículos inexistentes y el *consenso semántico* las premisas falsas sobre normas reales, alcanzando 9/10 en abstenciones y elevando el total a **43/50 (86 %)**. Este ajuste se diseñó observando las trazas de error de estas mismas preguntas. El único fallo remanente (P44) ocurrió al alucinar el modelo 4B que el artículo figuraba en el inventario.
2. **Casos límite (banco difícil):** 25 consultas de estrés evaluaron capacidades ausentes en D2: a) *cálculo numérico* (titulación 60 % asignaturas, 40 % memoria, RI-FI Art. 30); b) *prelación simultánea*; y c) *plazos excepcionales* (suspensión $>$ 3 años). Mientras D2 omitió condiciones o falló en aritmética (16/25, 64 %), los agentes resolvieron estos razonamientos multi-regla alcanzando **18/25 (72 %)** bajo pauta externa estricta (y 21/25, 84 % de aceptación interna del Auditor).

5. Diagnóstico de fallos, verificación y coste

- **Auditor y discrepancia interno-externa:** El validador normalizado permitió al Auditor aceptar 21/25 respuestas. Sin embargo, bajo pauta externa estricta se obtienen 18/25 aciertos (72 %): el Auditor aceptó internamente 3 respuestas con imprecisiones no detectadas (cálculo sin división en H07, plazo no aplicable en H12 y fecha engañosa en H23). En las 4 restantes hubo abstención técnica legítima: 3 por agotar presupuesto de 12 llamadas en cálculos complejos (H03, H04, H06) y 1 por formato inválido en premisa falsa (H20).
- **Interpretación de ablaciones:** En las 40 consultas vigentes del banco base, el sistema completo y las variantes sin descomposición y sin completitud obtienen 34/40 (85 %), mientras que sin verificación se obtienen 32/40 (80 %). La brecha en el total de 50 preguntas proviene de las 9 premisas falsas resueltas tras incorporar consenso en el orquestador. En el conjunto difícil, retirar completitud o descomposición reduce el acierto a 12/25 y 14/25, lo que sugiere que la verificación estructurada contribuye a mitigar alucinaciones en razonamientos multi-regla.
- **Compensación de coste:** La deliberación requiere 4,5 llamadas de modelo y ∼133 s por consulta en GPU T4 frente a 1 llamada y 15 s de RAG D2, un coste justificable únicamente ante consultas de alta complejidad normativa.

6. Reproducibilidad y repositorio

El repositorio contiene el código ejecutable, prompts versionados en archivos externos, semillas y trazas completas de las 450 respuestas con 25 snapshots ZIP inmutables. El cuaderno en Colab permite reproducir las corridas en GPU T4 de forma directa.