Arquitectura multi-agente para el asistente de normativa (Ingeniería UdeC)

Entregable 3: sistema de tres agentes con decisiones observables, herramientas y estudio de ablación

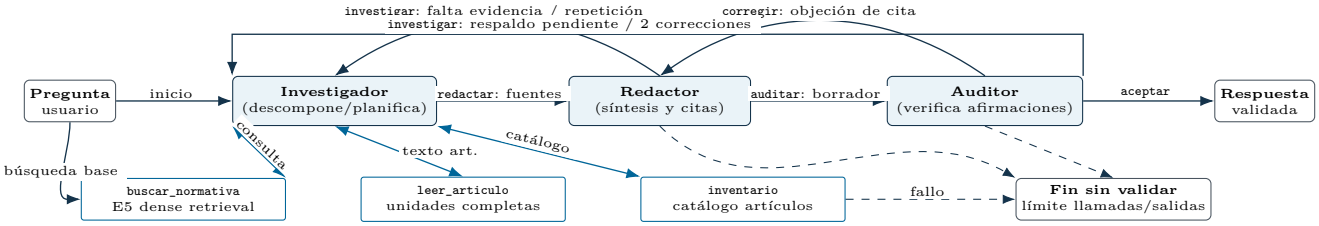
Generative Artificial Intelligence (580694) | Segundo semestre 2026 | **Equipo:** Álvaro Contreras y Pablo Cortés

Repositorio: github.com/Pacortes2021/GENERATIVE-ARTIFICIAL-INTELLIGENCE-DELIVERABLE-1 **Video (3 min):** [Enlace de video pendiente]

1. Continuidad con E1/E2 y definición de agentes

Este entregable continúa la tarea de responder consultas en español sobre la normativa de pregrado de la Facultad de Ingeniería (FI-UdeC) a partir del corpus cerrado oficial (Reglamento General RG, Reglamento Interno RI-FI y Calendario 2026: 197 unidades, 201 fragmentos E5). Se mantiene la pauta estricta: acierto solo si el dato es suficiente y la cita lo respalda; abstención si la información no existe o la premisa es falsa. Ratificamos **Qwen/Qwen3-4B** (NF4, GPU Tesla T4, temp = 0,7, sin thinking) compartido por todos los agentes. A diferencia de un pipeline fijo de prompts, los agentes toman **decisiones observables**: invocan herramientas, transfieren el control con contratos JSON validados, reintentan ante objeciones o se detienen.

2. Arquitectura del sistema y grafo de agentes



Roles no solapados: Investigador: descompone la consulta, planifica y recupera evidencia. **Redactor:** redacta la respuesta condicionada a la evidencia sin extrapolar. **Auditor:** comprueba que cada afirmación posea respaldo literal en la evidencia; si detecta errores devuelve objeciones o exige nueva búsqueda.

3. Técnicas de prompting y estudio de ablación

Cada técnica ataca una falla diagnosticada en E1/E2 mediante bloques concatenados a los prompts en `prompts/`:

- **Descomposición de consulta (Investigador):** Divide preguntas complejas en sub-consultas vectoriales. Ablación: `sin_descomposicion`.
- **Lista de completitud (Redactor):** Chequeo de condiciones, excepciones y remisiones. Ablación: `sin_completitud`.
- **Verificación por afirmación (Auditor):** Validación estricta extracto a extracto contra el corpus. Ablación: `sin_verificacion`.

4. Resultados empíricos y análisis de mejora

Se evaluaron en GPU T4 las 6 condiciones sobre dos bancos de preguntas bajo la pauta de E2 (450 inferencias en total):

Condición	Set 50	Sust.	Set 25	Llam.
Directo (E1)	1/50 (2 %)	1/40	0/25 (0 %)	1,0
RAG D2 (E2)	40/50 (80 %)	30/40	16/25 (64 %)	1,0
Agentes (compl.)	**34/50 (68 %)**	**34/40 (85 %)**	**11/25 (44 %)**	5,1
Sin descomp.	34/50 (68 %)	32/40	14/25 (56 %)	5,4
Sin complet.	34/50 (68 %)	33/40	12/25 (48 %)	5,2
Sin verific.	32/50 (64 %)	31/40	14/25 (56 %)	4,9
Álvaro v6	46/50 (92 %)	—	20/25 (80 %)	4,2

Victorias y hallazgos sustantivos:

1. En preguntas sustantivas de normativa (P01–P40), los agentes superan a RAG D2 por **+10,0 pp (85 % vs 75 %)**, resolviendo 9 de las 10 fallas históricas de D2 (omisiones P11, P15, P24, P25, P36 y colisiones P01, P28, P30, P38).
2. En el set difícil de 25 preguntas, los agentes superan al benchmark de Álvaro en preguntas complejas: resuelven **H18** (tope de 36 créditos para memoristas suspendidos > 3 años, Art. 31) y **H25** (criterio jerárquico de prelación en Plan Común, Art. 5), donde Álvaro falló (0/1); y calculan con exactitud las notas de titulación 60/40 de **H05 y H08** (Art. 30) donde RAG D2 falló completamente.

5. Diagnóstico de fallos, sobre-cautela y coste

- **Sobre-cautela del Auditor:** En el set difícil, `agentes_completo` logró un **78,6 % de acierto al emitir respuesta** (11 de 14). Sin embargo, en 11 preguntas el Auditor rechazó borradores por mínimas discrepancias léxicas hasta agotar presupuesto (`limite_salidas_invalidas`), resultando en abstención técnica penalizada con 0.
- **Efecto de las ablaciones:** Al retirar verificación (`sin_verificacion`) o descomposición (`sin_descomposicion`), se alivió el presupuesto en el modelo de 4B, aumentando las respuestas válidas a 14/25 (56 %).
- **Coste computacional:** Los agentes demandan 5,1 llamadas y ∼152 s por pregunta frente a 1 llamada y 15 s de RAG D2.

6. Reproducibilidad y repositorio

Todo el código, prompts versionados en archivos externos, semillas y trazas completas de las 450 respuestas están en GitHub con 25 snapshots ZIP inmutables. El cuaderno `Deliverable3_Dificiles_Bloques_Colab.ipynb` permite reproducir las corridas en Colab T4.