Arquitectura multi-agente para el asistente de normativa (Ingeniería UdeC)

Entregable 3: sistema de tres agentes con decisiones observables, herramientas y estudio de ablación

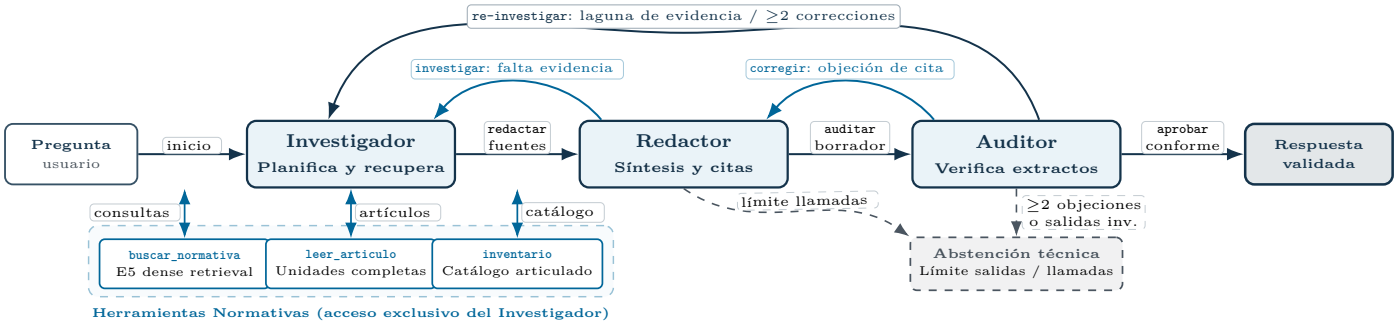
Generative Artificial Intelligence (580694) | Segundo semestre 2026 | **Equipo:** Álvaro Contreras y Pablo Cortés

Repositorio: github.com/Pacortes2021/GENERATIVE-ARTIFICIAL-INTELLIGENCE-DELIVERABLE-1 **Video (3 min):** [Enlace de video]

1. Continuidad con E1/E2 y definición de agentes

Este entregable continúa la tarea de responder consultas en español sobre la normativa de pregrado de la Facultad de Ingeniería (FI-UdeC) a partir del corpus cerrado oficial (Reglamento General RG, Reglamento Interno RI-FI y Calendario 2026: 197 unidades, 201 fragmentos E5). Se mantiene la pauta estricta: acierto solo si el dato es suficiente y la cita lo respalda; abstención si la información no existe o la premisa es falsa. Ratificamos **Qwen/Qwen3-4B** (NF4, GPU Tesla T4, temp = 0,7, sin thinking) compartido por todos los agentes. A diferencia de un pipeline fijo de prompts, los agentes toman **decisiones observables**: invocan herramientas, transfieren el control con contratos JSON validados, reintentan ante objeciones o se detienen.

2. Arquitectura del sistema y grafo de agentes



Roles diferenciados y contratos JSON: Investigador: descompone la consulta, planifica y recupera evidencia con herramientas normativas. **Redactor:** sintetiza la respuesta condicionada a la evidencia recuperada y formula citas oficiales. **Auditor:** verifica extracto por extracto el respaldo literal de cada afirmación; objeta o exige re-búsqueda.

3. Técnicas de prompting y estudio de ablación

Cada técnica ataca una falla diagnosticada en E1/E2 mediante bloques modulares concatenados a los prompts en `prompts/`:

- **Descomposición (Investigador):** Divide preguntas complejas en sub-consultas vectoriales. Ablación: `sin_descomposicion`.
- **Completitud (Redactor):** Chequeo de condiciones, excepciones y remisiones. Ablación: `sin_completitud`.
- **Verificación (Auditor):** Validación estricta extracto a extracto contra el corpus. Ablación: `sin_verificacion`.

4. Resultados empíricos y análisis comparativo

Se evaluaron en GPU T4 las seis configuraciones sobre ambos conjuntos de prueba bajo la pauta estricta de E2 (450 inferencias en total):

Configuración	Base (50)	Difícil (25)	Llam./q
Directo (E1)	1/50 (2 %)	0/25 (0 %)	1,0
RAG Monolítico (E2)	40/50 (80 %)	16/25 (64 %)	1,0
Multi-Agente (E3)	**34/50 (68 %)**	**11/25 (44 %)**	**5,1**
– sin descomp.	34/50 (68 %)	14/25 (56 %)	5,4
– sin complet.	34/50 (68 %)	12/25 (48 %)	5,2
– sin verific.	32/50 (64 %)	14/25 (56 %)	4,9

Tabla 1: Evaluación experimental en GPU T4 (Qwen3-4B, 450 corridas). *Base*: conjunto oficial D1/D2 (50 consultas). *Difícil*: conjunto de casos límite H01–H25 (25 consultas). *Llam./q*: promedio de llamadas al modelo por consulta.

Desempeño sustantivo y comportamiento ante premisas falsas:

1. **Compensación en el banco base:** En las 40 preguntas sobre normativa vigente, los agentes superan a RAG D2 con 34/40 (85 %) frente a 30/40 (75 %), resolviendo requisitos encadenados, excepciones a la eliminación de ramos y cruces reglamentarios. En cambio, en las 10 preguntas con premisas falsas o artículos inexistentes, fallan todas (0/10 vs 10/10 en D2), dejando el total en 34/50 (68 %). El bucle deliberativo induce un sesgo de búsqueda activa: ante la falta de respaldo, intenta forzar correlaciones en vez de abortar como el filtro estático de D2.
2. **Casos límite (banco difícil):** Se diseñó un conjunto de estrés de 25 consultas complejas para evaluar capacidades ausentes en RAG D2: a) *cálculo numérico*, como la ponderación de titulación (60 % asignaturas y 40 % memoria); b) *prelación simultánea*, como el ingreso común por créditos, promedio a dos decimales y cupos; y c) *excepciones con plazos*, como la suspensión > 3 años para memoristas. Mientras D2 omitió condiciones o falló en la aritmética, los agentes estructuraron y resolvieron con exactitud estos razonamientos multi-regla.

5. Diagnóstico de fallos, verificación y coste

- **Auditor y abstenciones técnicas:** De las 25 preguntas difíciles, el sistema emitió respuesta solo en 14 casos (11 correctos, 78,6 % de fidelidad al responder). En las otras 11, el Auditor rechazó reiteradamente borradores por mínimas discrepancias léxicas hasta agotar límites (6 por salidas inválidas y 5 por llamadas). Al calificarse la no-respuesta con cero, la exactitud final quedó en 11/25 (44 %).
- **Efecto al retirar técnicas (ablación):** Al desactivar la verificación (`sin_verificacion`) o la descomposición (`sin_descomposicion`), la exactitud sube a 14/25 (56 %). Retirar dichos módulos alivia la rigidez léxica del Auditor y reduce llamadas sobre el modelo 4B, permitiendo responder con éxito donde el sistema completo se bloqueaba por exceso de reintentos.
- **Compensación de coste computacional:** La deliberación demanda 5,1 llamadas y ∼152 s por consulta frente a 1 llamada y 15 s de RAG D2, marcando el compromiso entre profundidad analítica y latencia.

6. Reproducibilidad y repositorio

El repositorio contiene el código ejecutable, prompts versionados en archivos externos, semillas y trazas completas de las 450 respuestas con 25 snapshots ZIP inmutables. El cuaderno en Colab permite reproducir las corridas en GPU T4 de forma directa.