# Tres agentes para normativa UdeC

Álvaro Contreras y Pablo Cortés

Generative Artificial Intelligence (580694)

Deliverable 3 27 de octubre de 2026

**BORRADOR DE DESARROLLO: faltan el lote final, las ablaciones y el enlace de video.**

## Continuidad, tarea y criterio

Preguntas en español sobre RG, RI-FI y calendario académico 2026: mismo corpus de D2 (197 unidades; 201 fragmentos) y mismas 50 preguntas de desarrollo. Se busca resolver omisiones, remisiones incompletas y citas que no respaldan la respuesta. Una salida correcta entrega lo solicitado, con respaldo pertinente y sin añadidos falsos; rechaza premisas falsas cuando corresponde. La evaluación externa usa la pauta D2; aceptar internamente no equivale a acertar.

## Arquitectura: decisiones observables, no una secuencia fija

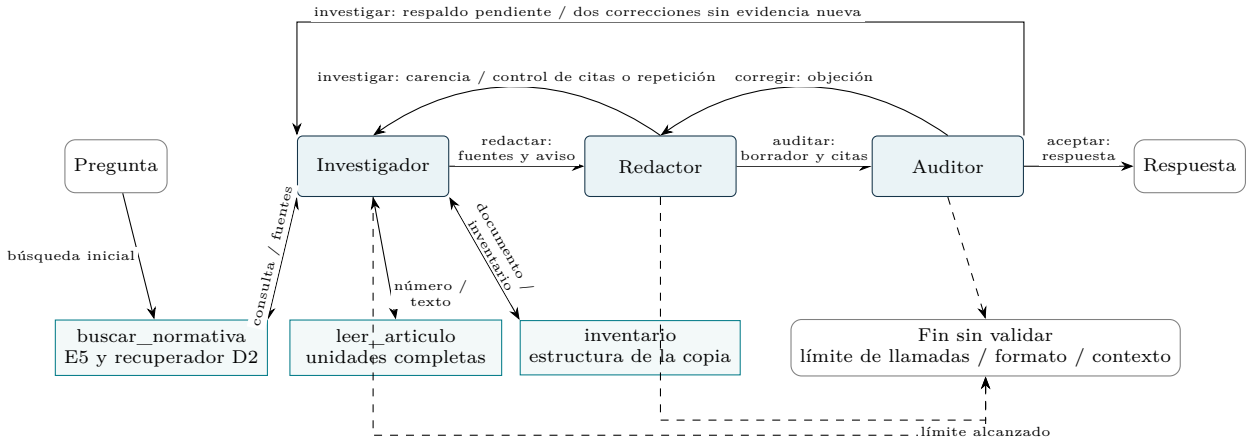


Las flechas dobles intercambian solicitudes y fuentes. Cada llamada recibe pregunta, evidencia, observaciones, borrador, mensaje y presupuesto; devuelve una decisión JSON validada. El investigador elige herramientas o entrega; el redactor redacta o pide datos; el auditor acepta, corrige o investiga. El controlador registra además transferencias por cita desconocida o repetición, e invalida borradores obsoletos.

## Técnicas y ablaciones

| Agente | Técnica y fallo que aborda | Ablación de un bloque externo |
|---|---|---|
| Investigador | Descomposición explícita: cobertura de partes y remisiones | `sin_descomposicion` |
| Redactor | Lista de completitud: omisiones y condiciones | `sin_completitud` |
| Auditor | Verificación por afirmación: citas y añadidos | `sin_verificacion` |

Se retira solo el bloque de prompting indicado; se mantienen roles, herramientas, protocolo y límites. Son contribuciones incrementales: D2 ya contiene expansión de remisiones y el auditor genérico permanece.

## Resultados disponibles: pilotos diagnósticos, no experimento final

| Versión y conjunto | Baseline | RAG D2 | Agentes | Ablaciones |
|---|---|---|---|---|
| Piloto v1: P05/P25/P38/P41 | 0/4 | 2/4 | 0/4 | Pendientes |
| Piloto v2: mismos cuatro casos | 0/4 | 2/4 | 1/4 | Pendientes |
| Piloto v3: mismos cuatro casos | 0/4 | 2/4 | 1/4 | Pendientes |
| Piloto v4: mismos cuatro casos | 0/4 | 2/4 | 1/4 | Pendientes |
| Lote v4: 50 preguntas | Pendiente | Pendiente | Pendiente | Pendientes |

V4 mantiene P05 correcto. P25 desarrolla las categorías, pero omite que las obligatorias reprobadas sigan sin aprobar; P38 no respalda el ámbito específico. P41 reconoce ausencia en borradores, pero agota 12 llamadas por revisiones repetidas: D2 sí responde. V4 usa 21 llamadas, 3.228 tokens de salida y 723,35 s de generación; D2, 78,77 s. No hay salidas cortadas. El lote de seis condiciones está en ejecución con v4 congelada; no se ha demostrado mejora sobre D2.

## Reproducción y límites

Los tres agentes comparten Qwen3-4B abierto, NF4 en T4, sin thinking, temperatura 0,7; E5 solo recupera. Por entrada: 12 llamadas, 6 herramientas (incluida búsqueda inicial), 3 salidas inválidas; contexto 8.192, salida 1.024 y margen 64 tokens. Baseline y D2 conservan sus prompts originales. Cada ZIP congela código, corpus, prompts, semillas, respuestas, tiempos y trazas; los juicios se vinculan por hashes. Las 50 preguntas se usaron en desarrollo: no demuestran generalización.

**Repositorio:** github.com/Pacortes2021/GENERATIVE-ARTIFICIAL-INTELLIGENCE-DELIVERABLE-1

**Video abierto:** pendiente de grabación y publicación. **Entrega final:** sustituir esta tabla por las seis condiciones evaluadas y verificar el enlace.