Tres agentes para normativa UdeC

Álvaro Contreras y Pablo Cortés Generative Artificial Intelligence (580694)

Deliverable 3 27 de octubre de 2026

BORRADOR DE DESARROLLO: faltan el lote final, las ablaciones y el enlace de video.

Continuidad, tarea y criterio

Preguntas en español sobre RG, RI-FI y calendario académico 2026: mismo corpus de D2 (197 unidades; 201 fragmentos) y mismas 50 preguntas de desarrollo. Se busca resolver omisiones, remisiones incompletas y citas que no respaldan la respuesta. Una salida correcta entrega lo solicitado, con respaldo pertinente y sin añadidos falsos; rechaza premisas falsas cuando corresponde. La evaluación externa usa la pauta D2; aceptar internamente no equivale a acertar.

Arquitectura: decisiones observables, no una secuencia fija

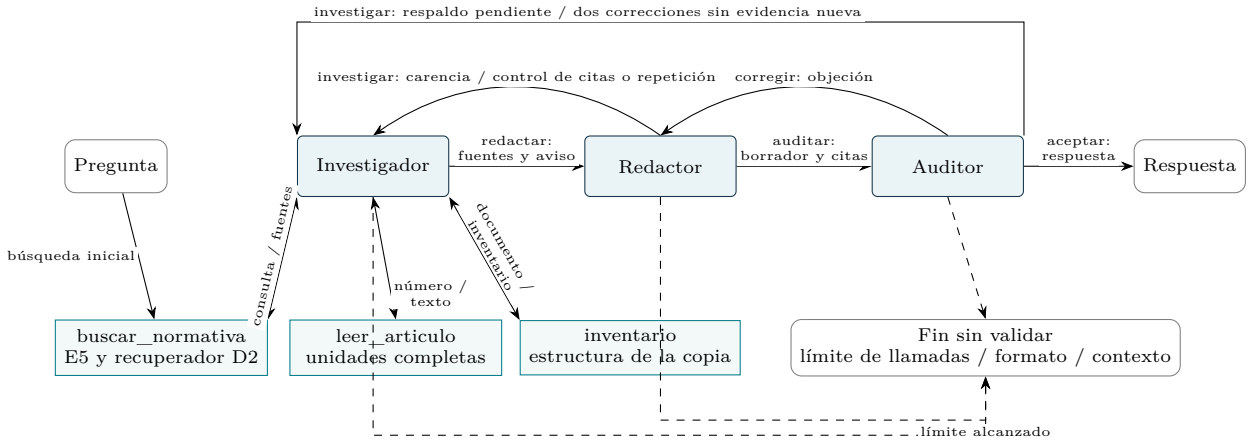

Las flechas dobles intercambian solicitudes y fuentes. Cada llamada recibe pregunta, evidencia, observaciones, borrador, mensaje y presupuesto; devuelve una decisión JSON validada. El investigador elige herramientas o entrega; el redactor redacta o pide datos; el auditor acepta, corrige o investiga. El controlador registra además transferencias por cita desconocida o repetición, e invalida borradores obsoletos.

Técnicas y ablaciones

Agente	Técnica y fallo que aborda	Ablación de un bloque externo
Investigador	Descomposición explícita: cobertura de partes y remisiones	`sin_descomposicion`
Redactor	Lista de completitud: omisiones y condiciones	`sin_completitud`
Auditor	Verificación por afirmación: citas y añadidos	`sin_verificacion`

Se retira solo el bloque de prompting indicado; se mantienen roles, herramientas, protocolo y límites. Son contribuciones incrementales: D2 ya contiene expansión de remisiones y el auditor genérico permanece.

Resultados disponibles: pilotos diagnósticos, no experimento final

Versión y conjunto	Baseline	RAG D2	Agentes	Ablaciones
Piloto v1: P05/P25/P38/P41	0/4	2/4	0/4	Pendientes
Piloto v2: mismos cuatro casos	0/4	2/4	1/4	Pendientes
Piloto v3: mismos cuatro casos	0/4	2/4	1/4	Pendientes
Versión v4 / lote 50 preguntas	Pendiente	Pendiente	Pendiente	Pendientes

V3 mantiene P05 correcto, pero omite desarrollar la remisión en P25 y no respalda el ámbito específico en P38. P41 termina por formato pese a tener inventario de ausencia; D2 sí responde ese caso. Los agentes usaron 15 llamadas, 1.963 tokens de salida y 380,05 s de generación, frente a 1.453,74 s en v2; D2 v3: 71,83 s. No hubo salidas cortadas. V4 normaliza solicitudes explícitas de herramienta y refuerza los bloques de prompting; todavía no tiene resultados.

Reproducción y límites

Los tres agentes comparten Qwen3-4B abierto, NF4 en T4, sin thinking, temperatura 0,7; E5 solo recupera. Por entrada: 12 llamadas, 6 herramientas (incluida búsqueda inicial), 3 salidas inválidas; contexto 8.192, salida 1.024 y margen 64 tokens. Baseline y D2 conservan sus prompts originales. Cada ZIP congela código, corpus, prompts, semillas, respuestas, tiempos y trazas; los juicios se vinculan por hashes. Las 50 preguntas se usaron en desarrollo: no demuestran generalización.

Repositorio: github.com/Pacortes2021/GENERATIVE-ARTIFICIAL-INTELLIGENCE-DELIVERABLE-1

Video abierto: pendiente de grabación y publicación. **Entrega final:** sustituir esta tabla por las seis condiciones evaluadas y verificar el enlace.