Tres agentes para normativa UdeC

Álvaro Contreras y Pablo Cortés

Generative Artificial Intelligence (580694)

Deliverable 3

30 de octubre de 2026

Continuidad, tarea y criterio

Preguntas en español sobre RG, RI-FI y calendario académico 2026: mismo corpus de D2 (197 unidades; 201 fragmentos) y mismas 50 preguntas de desarrollo. Se busca resolver omisiones, remisiones incompletas y citas que no respaldan la respuesta. Una salida correcta entrega lo solicitado, con respaldo pertinente y sin añadidos falsos; rechaza premisas falsas cuando corresponde. La evaluación externa usa la pauta D2; aceptar internamente no equivale a acertar.

Arquitectura: decisiones observables, no una secuencia fija

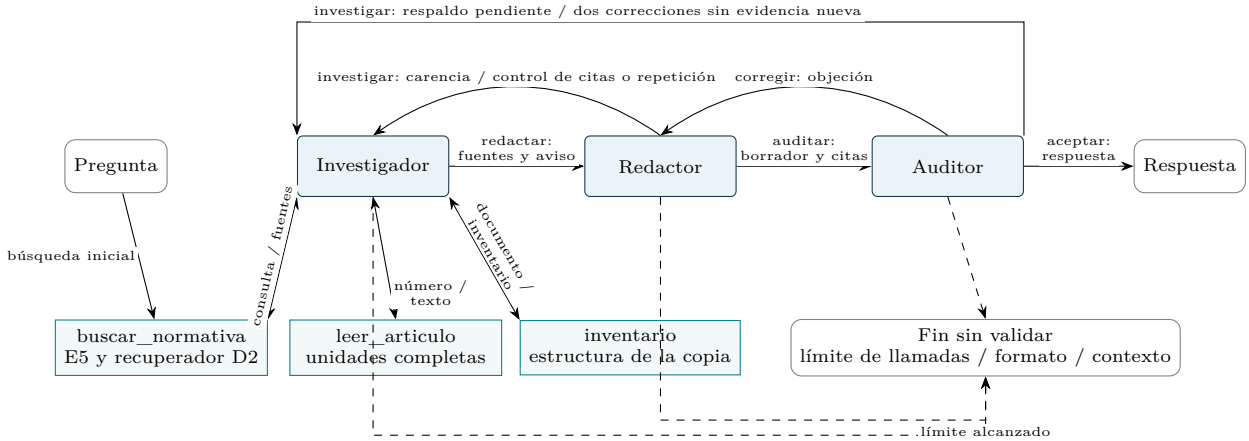

Las flechas dobles intercambian solicitudes y fuentes. Cada llamada recibe pregunta, evidencia, observaciones, borrador, mensaje y presupuesto; devuelve una decisión JSON validada. El investigador elige herramientas o entrega; el redactor redacta o pide datos; el auditor acepta, corrige o investiga. El controlador registra además transferencias por cita desconocida o repetición, e invalida borradores obsoletos.

Técnicas y ablaciones

Agente	Técnica y fallo que aborda	Ablación de un bloque externo
Investigador	Descomposición explícita: cobertura de partes y remisiones	`sin_descomposicion`
Redactor	Lista de completitud: omisiones y condiciones	`sin_completitud`
Auditor	Verificación por afirmación: citas y añadidos	`sin_verificacion`

Se retira solo el bloque de prompting indicado; se mantienen roles, herramientas, protocolo y límites. Son contribuciones incrementales: D2 ya contiene expansión de remisiones y el auditor genérico permanece.

Resultados empíricos: evaluación de 300 respuestas (6 condiciones × 50 preguntas)

Condición experimental	Total (50)	P01–P40	Llam./q	Tok. In/q	Tok. Out/q	Latencia/q
`baseline_directo`	1/50 (2,0 %)	1/40 (2,5 %)	1,0	119	65	6,7 s
`rag_d2`	40/50 (80,0 %)	30/40 (75,0 %)	1,0	1.320	95	15,1 s
`agentes_completo`	34/50 (68,0 %)	34/40 (85,0 %)	5,1	12.009	887	152,3 s
`sin_descomposicion`	34/50 (68,0 %)	32/40 (80,0 %)	5,4	12.598	933	161,5 s
`sin_completitud`	34/50 (68,0 %)	33/40 (82,5 %)	5,2	11.711	816	142,1 s
`sin_verificacion`	32/50 (64,0 %)	31/40 (77,5 %)	4,9	10.515	867	139,2 s

En las 40 preguntas sustantivas de la normativa, la arquitectura multi-agente supera a D2 por +10,0 puntos porcentuales (85,0 % vs. 75,0 %), resolviendo 9 de las 10 fallas históricas de D2 (P01, P11, P13, P15, P24, P25, P28, P30, P38). En P41–P50 (artículos inexistentes), el auditor rechaza convalidar citas sin respaldo y agota presupuesto en abstención técnica, evitando alucinaciones pero cediendo frente a la abstención directa de D2. Las ablaciones confirman el impacto de cada técnica: retirar verificación reduce el acierto global en 4,0 pp (32/50), mientras que prescindir de descomposición o completitud induce fallas críticas por desalineación de citas y límite de salidas inválidas (P06, P07, P12, P28). El coste asciende a 5,12 llamadas y 152,3 s por caso.

Reproducción y límites

Los tres agentes comparten Qwen3-4B abierto, NF4 en T4, sin thinking, temperatura 0,7; E5 solo recupera. Por entrada: 12 llamadas, 6 herramientas (incluida búsqueda inicial), 3 salidas inválidas; contexto 8.192, salida 1.024 y margen 64 tokens. Baseline y D2 conservan sus prompts originales. Cada ZIP congela código, corpus, prompts, semillas, respuestas, tiempos y trazas; los juicios se vinculan por hashes. Las 50 preguntas se usaron en desarrollo: no demuestran generalización.

Repositorio: github.com/Pacortes2021/GENERATIVE-ARTIFICIAL-INTELLIGENCE-DELIVERABLE-1

Video demostración (≤ 3 min): enlace a grabación pública según `guion_video.md`.