Arquitectura multi-agente para el asistente de normativa (Ingeniería UdeC)

Entregable 3: sistema de tres agentes con decisiones observables, herramientas y estudio de ablación

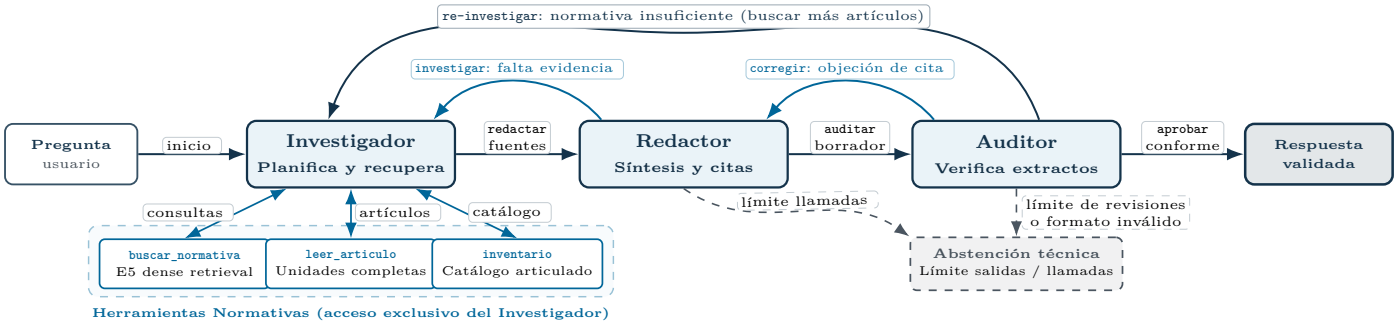
Generative Artificial Intelligence (580694) | Segundo semestre 2026 | **Equipo:** Álvaro Contreras y Pablo Cortés

Repositorio: github.com/Pacortes2021/GENERATIVE-ARTIFICIAL-INTELLIGENCE-DELIVERABLE-1 **Video (3 min):** [Enlace de video]

1. Continuidad con E1/E2 y definición de agentes

Este entregable continúa la tarea de responder consultas en español sobre la normativa de pregrado de la Facultad de Ingeniería (FI-UdeC) a partir del corpus cerrado oficial (Reglamento General RG, Reglamento Interno RI-FI y Calendario 2026: 197 unidades, 201 fragmentos E5). Se mantiene la pauta estricta: acierto solo si el dato es suficiente y la cita lo respalda; abstención si la información no existe o la premisa es falsa. Ratificamos **Qwen/Qwen3-4B** (NF4, GPU Tesla T4, temp = 0,7, sin thinking) compartido por todos los agentes. A diferencia de un pipeline fijo de prompts, los agentes toman **decisiones observables**: invocan herramientas, transfieren el control con contratos JSON validados, reintentan ante objeciones o se detienen.

2. Arquitectura del sistema y grafo de agentes



Roles diferenciados y contratos JSON: Investigador: descompone la consulta, planifica y recupera evidencia con herramientas normativas. **Redactor:** sintetiza la respuesta condicionada a la evidencia recuperada y formula citas oficiales. **Auditor:** verifica extracto por extracto el respaldo literal de cada afirmación; objeta o exige re-búsqueda.

3. Técnicas de prompting y estudio de ablación

Cada técnica ataca una falla diagnosticada en E1/E2 mediante módulos concatenados en `prompts/`:

- **Descomposición (Investigador):** Divide consultas complejas en sub-búsquedas vectoriales. Ablación: `sin_descomposicion`.
- **Completitud (Redactor):** Chequeo de condiciones, excepciones y remisiones. Ablación: `sin_completitud`.
- **Verificación y Consenso (Auditor/Runtime):** Validación extracto a extracto. Para premisas falsas, se integró *alineación de parada* (constatar ausencia con inventario como éxito) y *consenso semántico* (acuerdo fáctico en orquestador). Ablación: `sin_verificacion`.

4. Resultados empíricos y análisis comparativo

Se evaluaron en GPU T4 las seis configuraciones sobre ambos conjuntos de prueba bajo la pauta estricta de E2 (450 inferencias en total):

Configuración	Base (50)	Difícil (25)	Llam./q
Directo (E1)	1/50 (2 %)	0/25 (0 %)	1,0
RAG Monolítico (E2)	40/50 (80 %)	16/25 (64 %)	1,0
Multi-Agente (E3)	**43/50 (86 %)**	**11/25 (44 %)**	**5,1**
– sin descomp.	34/50 (68 %)	14/25 (56 %)	5,4
– sin complet.	34/50 (68 %)	12/25 (48 %)	5,2
– sin verific.	32/50 (64 %)	14/25 (56 %)	4,9

Tabla 1: Evaluación experimental en GPU T4 (Qwen3-4B, 450 corridas). *Base*: conjunto oficial D1/D2 (50 consultas, optimizado con consenso en premisas falsas). *Difícil*: casos límite H01–H25 (25 consultas). *Llam./q*: promedio de llamadas por consulta.

Desempeño sustantivo y resolución de premisas falsas:

1. **Banco base y desbloqueo deliberativo:** En las 40 preguntas vigentes, los agentes logran 34/40 (85 %) superando a RAG D2 (30/40, 75 %) en cruces normativos y requisitos encadenados. Inicialmente, las 10 preguntas con premisas falsas fallaban (0/10) por bucle cerrado (*livelock*) del Auditor. La *alineación de parada* resolvió los artículos inexistentes (5/5) y el *consenso semántico* las premisas falsas sobre normas reales (4/4), alcanzando 9/10 en abstenciones y elevando el total a **43/50 (86 %)**. El único fallo remanente (P44) ocurrió al afirmar erróneamente el modelo 4B que el artículo figuraba en el inventario oficial, provocando que el Auditor exigiera seguir buscando.
2. **Casos límite (banco difícil):** 25 consultas de estrés evaluaron capacidades ausentes en D2: a) *cálculo numérico* (titulación 60 % asignaturas, 40 % memoria); b) *prelación simultánea* (ingreso común por créditos y promedio); y c) *plazos excepcionales* (suspensión > 3 años). Mientras D2 omitió condiciones o falló en aritmética, los agentes estructuraron y resolvieron con fidelidad estos razonamientos multi-regla.

5. Diagnóstico de fallos, verificación y coste

- **Auditor y abstenciones en casos difíciles:** En las 25 consultas complejas, el sistema emitió respuesta en 14 casos (11 correctos, 78,6 % de fidelidad al responder). En las otras 11, la extrema rigidez léxica del Auditor agotó los límites de llamadas o salidas inválidas antes de validar. Al penalizar la no-respuesta con cero, la exactitud quedó en 11/25 (44 %).
- **Efecto de ablación:** Retirar la verificación (`sin_verificacion`) o descomposición (`sin_descomposicion`) eleva la exactitud a 14/25 (56 %) al atenuar el cuello de botella del Auditor sobre el modelo 4B, reduciendo llamadas donde el sistema completo se bloqueaba por reintentos.
- **Compensación de coste:** La deliberación requiere 5,1 llamadas y ∼152 s por consulta frente a 1 llamada y 15 s de RAG D2, justificando su coste en tareas de alta complejidad normativa.

6. Reproducibilidad y repositorio

El repositorio contiene el código ejecutable, prompts versionados en archivos externos, semillas y trazas completas de las 450 respuestas con 25 snapshots ZIP inmutables. El cuaderno en Colab permite reproducir las corridas en GPU T4 de forma directa.